



(a) 360M 배치 1: 가중치 evict-first (cuBLAS gemv)



(b) 360M 배치 4: 가중치 일반 로드 (CUTLASS GEMM) + R3 개입



96 MiB의 점은 실측(RTX PRO 5000). 그보다 큰 용량은 v3(96 MiB에서만 검증)의 투영이며, 창 최대 크기가 L2의 4/3으로 함께 커진다고 가정했다. set-aside ≤ L2의 10/16.