




(a) 합성, 보류 150 설정 (H1c)



(b) 실제 LLM 디코드 141 설정 (R1)



(c) SmolLM-135M B1: 실측은 set-aside 와 무관



막대 색: 파랑 = 우리 모델, 주황 = 정책형 선행(AutoScratch, 코드 비공개라 논문의 의미론을 재구현), 회색 = 정책을 표현하지 못하는 도구(실제 코드 실행 또는 논문 식). 사전 고정 예측과 하드웨어 카운터(ncu) 비교.
 v3 = v2 + 로드 명령의 evict-first 클래스(적합 0; 합성에서는 v2와 같다). R1의 v3는 R1-D3를 본 뒤 SASS로 클래스를 정한 사후 분석(빛금).
 (b)의 Accel-Sim은 360M B1을 비용(트레이스 수 시간 + 시뮬레이션 약 1일) 때문에 돌리지 않아 135M B1-B8 94 설정만 채점했다(점선 막대, 순위 밖). 같은 설정에서 우리 v2 18.1, v3 9.4(사후).
 (c) 점선 = GPU-Tile-Sim L2·LLMCompass·Accel-Sim 2.0의 예측(정책 설정과 무관하게 워크로드마다 한 값).