




(a) 처음 보는 6 워크로드, 282 설정 (R2)



(b) set-aside 가 이득을 바꾸는가



(c) 360M B1 ctx 1536: 실선 S 12, 점선 S 60 (속 빈 표시)



예측은 모두 측정 전에 고정했다. v3의 로드 클래스(가중치를 evict-first로 읽는가)는 각 워크로드의 SASS에서 정했고, 새로 적합한 값은 없다(ϕ 0.3, 16-way는 v2 그대로).
 배치 1은 cuBLAS gemv(LDG.E.EF), 배치 2 이상은 CUTLASS GEMM(일반 로드). 정책을 못 보는 도구(GPU-Tile-Sim, MemExplorer)는 (b)에서 정의상 0이다.