


토큰 하나마다 모델 전체를 읽는다

weight 15.01 GB + KV 2.15 GB = 17.16 GB / step

HBM 실질 6.40 TB/s 로 나누면 2.66 ms

스텝의 59%



그런데 관행 스크리닝의 판정은
"지을 이유가 없다"

